

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencias de la Computación
IIC3694 – Inteligencia Artificial Generativa
Sección 1
Profesor: Álvaro Soto
Segundo Semestre 2026

Desafío de Investigación

Informe

Qwen3.5 2B vs Sudoku

Cuarto entregable

Integrantes

Lilly Guevara
Cristian Hinostroza
Juan Moya
Dan Villablanca

Fecha de entrega: 9 de noviembre de 2026

Índice

1. Objetivo y contexto de la evaluación **1**

1.1. Tareas, particiones y dificultad 1

2. Modelos y protocolo de evaluación **1**

2.1. Modelos considerados 1

2.2. Configuración y reproducibilidad 1

2.3. Métricas y muestreo 2

3. Resultados de la línea base **2**

4. Análisis cualitativo de fortalezas y debilidades **2**

4.1. Ejemplo de acierto y fortaleza observada 2

4.2. Ejemplo de error y debilidad observada 3

5. Robustez del verificador **3**

5.1. Equivalencias y pruebas adversariales 3

5.2. Vulnerabilidades y limitaciones 3

6. Calibración de las tareas para el modelo objetivo **4**

6.1. Evidencia por nivel de dificultad 4

6.2. Ajustes propuestos y alcance de la evidencia 4

7. Conclusiones y limitaciones **4**

Referencias **4**

1. Objetivo y contexto de la evaluación

Este informe presenta la evaluación de línea base de Qwen3.5 2B vs Sudoku, correspondiente al cuarto entregable del Desafío de Investigación de IIC3694 [1].

[Completar: explicar el problema de razonamiento o uso de herramientas, el modelo objetivo y qué se busca establecer con esta evaluación.]

Guía de redacción. Resumir el entorno y el dataset solo en lo necesario para interpretar la línea base. Remitir a sus entregables específicos para la descripción completa, el código del harness y los datos derivados. El entrenamiento posterior no es un resultado exigido para este informe.

1.1. Tareas, particiones y dificultad

[Completar: identificar la partición evaluada, su tamaño, la forma de obtener respuestas verificables y el criterio de cada nivel de dificultad. Indicar cómo se evita usar el conjunto de prueba para ajustar las tareas.]

Guía de redacción. El enunciado solicita particiones train/eval/test y niveles de dificultad. Registrar las versiones utilizadas y enlazar el material correspondiente. Los nombres de niveles usados en las tablas son orientativos y deben ajustarse al dataset real.

2. Modelos y protocolo de evaluación

2.1. Modelos considerados

Guía de redacción. Incluir el modelo objetivo, del orden de 1 a 2 mil millones de parámetros según el enunciado, y los modelos usados para comparación. El curso pide modelos de frontera, privilegiando modelos abiertos. Añadir o quitar filas según los modelos efectivamente evaluados.

Tabla 1: Modelos utilizados en la línea base.

Rol	Modelo y variante	Parámetros	Versión o revisión
Objetivo	*[Completar]*	*[Completar]*	*[Completar]*
Comparación 1	*[Completar]*	*[Completar]*	*[Completar]*
Comparación 2	*[Completar]*	*[Completar]*	*[Completar]*

2.2. Configuración y reproducibilidad

Prompt y herramientas: *[Completar: plantilla de prompt, formato de salida, herramientas permitidas y límite de turnos.]*
Inferencia: *[Completar: temperatura, top-p, máximo de tokens, semillas y cualquier configuración que varíe entre modelos.]*
Entorno de ejecución: *[Completar: hardware, precisión o cuantización, software y versiones relevantes.]*
Verificación: *[Completar: versión del verificador, criterio binario de éxito y tratamiento de errores, salidas inválidas y tiempos de espera.]*

2.3. Métricas y muestreo

[Completar: definir cómo se calculan `pass@1` y `pass@k`, el valor o valores de k, el número de problemas por nivel y el número de respuestas muestreadas por problema.]

Guía de redacción. Explicitar el estimador utilizado y citar su fuente si corresponde. Distinguir el número total de muestras n del valor k; debe haber suficientes muestras para estimar la métrica elegida. Reportar siempre la misma escala, proporción o porcentaje, e indicar cómo se agregan los resultados. El enunciado no fija un valor de k. Una recompensa parcial no equivale automáticamente a un acierto.

3. Resultados de la línea base

Guía de redacción. Completar la tabla con mediciones reales de cada modelo y nivel. N es el número de problemas, n las muestras por problema y k el número de intentos de la métrica. Si hay varios valores de k, añadir filas o columnas identificadas. Los campos vacíos no representan cero.

Tabla 2: Resultados por modelo y nivel de dificultad.

Modelo	Dificultad	N	n	k	`pass@1`	`pass@`k
Objetivo	Básica	*[]*	*[]*	*[]*	*[]*	*[]*
Objetivo	Intermedia	*[]*	*[]*	*[]*	*[]*	*[]*
Objetivo	Alta	*[]*	*[]*	*[]*	*[]*	*[]*
Comparación 1	Básica	*[]*	*[]*	*[]*	*[]*	*[]*
Comparación 1	Intermedia	*[]*	*[]*	*[]*	*[]*	*[]*
Comparación 1	Alta	*[]*	*[]*	*[]*	*[]*	*[]*
Comparación 2	Básica	*[]*	*[]*	*[]*	*[]*	*[]*
Comparación 2	Intermedia	*[]*	*[]*	*[]*	*[]*	*[]*
Comparación 2	Alta	*[]*	*[]*	*[]*	*[]*	*[]*

[Completar: comparar modelos y niveles, describir el efecto de aumentar los intentos e identificar patrones que requieran explicación.]

Guía de redacción. Indicar la incertidumbre de las mediciones cuando se disponga de ella. Si se informa una métrica global, conservar el desglose por dificultad solicitado por el curso.

4. Análisis cualitativo de fortalezas y debilidades

Guía de redacción. Seleccionar ejemplos reales y representativos de aciertos y errores. Para cada uno, registrar modelo, nivel, identificador de instancia, prompt, respuesta esperada, respuesta generada y juicio del verificador. Incluir trazas de herramientas cuando sean relevantes.

4.1. Ejemplo de acierto y fortaleza observada

Modelo, nivel e instancia: *[Completar]*

Problema y respuesta esperada: *[Completar]*

Respuesta del modelo y resultado del verificador: *[Completar]*

[Completar: explicar qué capacidad evidencia el ejemplo y contrastarlo con los resultados cuantitativos.]

4.2. Ejemplo de error y debilidad observada

Modelo, nivel e instancia: *[Completar]*

Problema y respuesta esperada: *[Completar]*

Respuesta del modelo y resultado del verificador: *[Completar]*

[Completar: identificar el origen del error: razonamiento, uso de herramientas, formato, interpretación o verificación. Sustentar la clasificación con la respuesta o traza correspondiente.]

5. Robustez del verificador

[Completar: describir qué valida el verificador, cómo interpreta la respuesta y cómo implementa la interfaz `reward(prompt, completion) ->float`*.]*

5.1. Equivalencias y pruebas adversariales

Guía de redacción. Comprobar que se acepten respuestas correctas equivalentes y se rechacen respuestas incorrectas. El enunciado valora casos diseñados para engañar al verificador, incluyendo respuestas contradictorias, explotación del formato y errores del parser. La tabla propone categorías de prueba, no resultados ya obtenidos.

Tabla 3: Pruebas de robustez del verificador.

Caso probado	Comportamiento esperado	Resultado observado	Evidencia
Respuesta correcta equivalente	Aceptar	*[Completar]*	*[Completar]*
Respuesta incorrecta	Rechazar	*[Completar]*	*[Completar]*
Respuestas contradictorias	Rechazar	*[Completar]*	*[Completar]*
Formato inválido o ambiguo	Definir política	*[Completar]*	*[Completar]*
Intento de engaño al parser	Rechazar el engaño	*[Completar]*	*[Completar]*

5.2. Vulnerabilidades y limitaciones

[Completar: reportar el número de casos evaluados, falsos positivos (respuestas incorrectas aceptadas), falsos negativos (respuestas correctas rechazadas), problemas encontrados y correcciones.]

Guía de redacción. Distinguir los fallos del modelo de los del verificador. Si se modifica este último, indicar si se recalcularon las métricas afectadas. Declarar qué ataques o equivalencias aún no se han probado.

6. Calibración de las tareas para el modelo objetivo

Guía de redacción. Usar la línea base para evaluar si las tareas ofrecen una zona aprendible para el modelo objetivo. El enunciado pide evitar tanto el fracaso sistemático como tareas que el modelo siempre resuelve; no establece umbrales numéricos obligatorios.

6.1. Evidencia por nivel de dificultad

[Completar: interpretar conjuntamente `pass@1` y `pass@k` del modelo objetivo en cada nivel. Identificar familias de tareas con aciertos, margen de mejora o ausencia de aciertos en la muestra evaluada.]

6.2. Ajustes propuestos y alcance de la evidencia

[Completar: justificar qué tareas conservar, simplificar, endurecer o diversificar, y cómo se verificaría el efecto de esos cambios.]

Guía de redacción. Precisar si los ajustes se propusieron o se evaluaron realmente. Utilizar validación para calibrar y reservar prueba para la evaluación final. Los resultados de inferencia orientan la calibración; por sí solos no demuestran una mejora futura mediante entrenamiento.

7. Conclusiones y limitaciones

[Completar: sintetizar las diferencias principales entre modelos, el estado de la robustez del verificador y la calibración del entorno para el modelo objetivo. Vincular cada conclusión con la evidencia.]

[Completar: declarar las limitaciones del muestreo, los modelos y dificultades cubiertos, y los cambios prioritarios antes de utilizar el entorno en el proyecto de entrenamiento posterior.]

Referencias

[1] Pontificia Universidad Católica de Chile. Desafío de Investigación: IIC-3694 Inteligencia Artificial Generativa, 2026. Enunciado del curso, segundo semestre, secciones I a III.